

Проектирование алгоритма формирования объяснений для модели машинного обучения CLIP

Студент: Кондренко Кирилл Павлович, гр. 25224
Руководитель практики: Яхьяева Гульнара Эркиновна

Новосибирск 2025

Актуальность

- Широкое применение мультимодальных моделей
- Сложность объяснения решений глубоких моделей
- Во многих областях от моделей требуется объяснимость
- Объяснимость и точность моделей коррелируют отрицательно



Цели и задачи

Цель: спроектировать алгоритм формирования объяснений для модели машинного обучения CLIP.

Задачи:

1. Проанализировать решения в области объяснимого ИИ.
2. Изучить архитектуру и принципы работы модели CLIP.
3. Спроектировать алгоритм формирования пояснений.

Подходы к объяснениям

- Через модель
- Аппроксимация модели в окрестности точки данных с помощью более простой (LIME)
- Оценка вклада признаков в предсказание (SHAP, Grad-CAM)
- Контрфактические объяснения — минимальные изменения, приводящие к другому предсказанию модели
- Гибридные

CLIP

- Модель работает с текстом и изображениями в одном векторном пространстве
- Для пары (текст, изображение) выдаёт их семантическую схожесть
- Демонстрирует высокие показатели на изображениях и текстах, которых не было при обучении

Применение CLIP

Классификация:

- Подаём на вход изображение и несколько текстов (классов)
- Модель относит изображение к одному из данных классов с некоторой степенью уверенности

Фильтрация:

- Подаём на вход изображение и несколько текстов (классов)
- Для каждого класса модель возвращает степень уверенности того, насколько класс есть в изображении
- Если степень уверенности $>$ порога, то изображение отфильтровывается

Применение CLIP

Поиск:

- Подаём на вход текст
- Модель генерирует эмбеddинг текста
- Ищем в векторной базе данных изображения, эмбеddинги которых близки к эмбеddингу текста

Объяснения для CLIP

- Нужно научиться для пары (текст, изображение) отвечать на вопрос, почему именно такая степень уверенности?
- **От изображения:** как изображение повлияло на степень уверенности?
- **От текста:** как текст повлиял на степень уверенности?

От изображения

Контрфактические объяснения:

1. С помощью обратного хода определяем, какой должен быть эмбеddинг e изображения, чтобы увеличить степень уверенности.
2. Ищем в векторной базе данных изображения, эмбеddинги которых близки к e .
3. Если для некоторого изображения степень уверенности стала нужной, то возвращаем его.

Важность признаков: С помощью обратного хода определяем и подсвечиваем пиксели изображения, которые больше всего повлияли на выход модели (нужно адаптировать существующие подходы под визуальный трансформер).

От текста

Контрфактические объяснения:

1. С помощью обратного хода определяем, какой должен быть эмбеddинг е текста, чтобы увеличить степень уверенности.
2. Ищем в векторной базе данных тексты, эмбеddинги которых близки к е.
3. Если для некоторого текста степень уверенности стала нужной, то возвращаем его.

Важность признаков: С помощью обратного хода определяем и подсвечиваем слова текста, которые больше всего повлияли на выход модели (нужно адаптировать существующие подходы под трансформер).

Заключение

1. Проанализированы решения в области объяснимого ИИ.
2. Изучена архитектура и принципы работы модели CLIP.
3. Спроектирован алгоритм генерации объяснений для модели CLIP.